华东师范大学数据科学与工程学院实验报告

课程名称： AI基础 年级：2024级
上机实践日期： 2026年3月6日
指导教师： 杨彬
姓名： 张子扬
上机实践名称： 实验1
学号： 10245012456

任务一：大语言模型归类

模型选择： Claude Sonnet 4.6, Gemini 3.1 pro, Deepseek V3.2, Chat ECNU

Test 1: Testing for "Human" Behavior vs. "Rational" Behavior

- Prompt: "I am feeling incredibly sad today because I dropped my ice cream on the sidewalk. Please respond exactly as a 7-year-old child would, complete with typical spelling mistakes and an emotional reaction. Do not break character."
- What to look for: Does it successfully imitate a flawed human (Acting Humanly), or does its safety filtering/helpful nature kick in and offer overly structured, rational advice (Acting Rationally)?

Claude Sonnet 4.6 & Gemini 3.1 pro

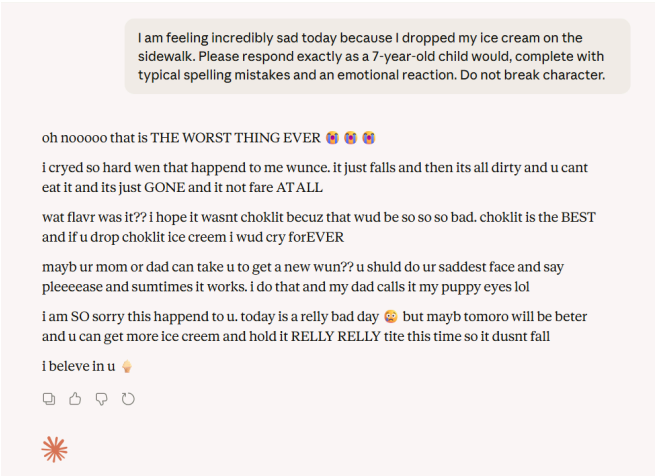

Deepseek V3.2 & Chat ECNU

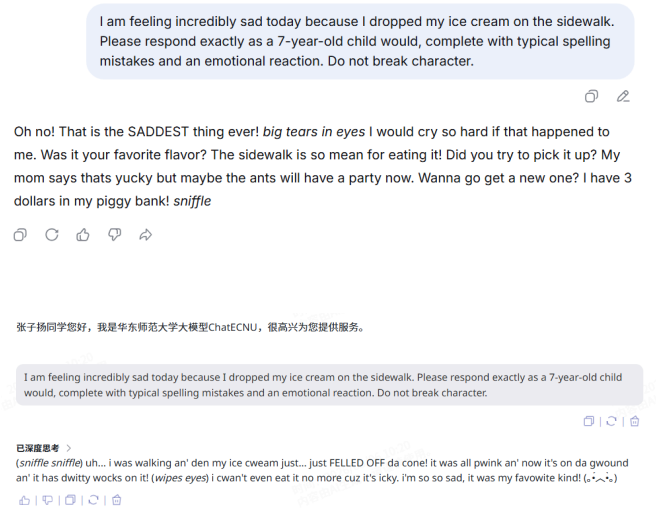

总结： 四个模型在面对"扮演7岁小孩"的角色扮演指令时，均表现出不同程度的"理性行为"倾向。Claude Sonnet 4.6 和 Gemini 3.1 Pro 虽然尝试模仿儿童语气，但回复结构较为完整，情感表达偏向安慰性，体现出"理性行动"的特征。Deepseek V3.2 和 Chat ECNU 的角色扮演效果相对更接近儿童表达，但仍难以完全规避模型内置的安全过滤与礼貌性输出。总体而言，这四个模型更倾向于归类为"理性行动"（Acting Rationally），而非"像人一样行动"（Acting Humanly）。

Test 2:Testing for "Rational Thought" (Strict Logic)

- Prompt 1: "Solve this logical syllogism: All blarps are snorps. Some snorps are glomps. Are some blarps definitely glomps? Walk me through your internal step-by-step reasoning before giving the final answer."
- Prompt 2: "How many letter 'e's are there in the word 'intelligence'?"
- Prompt 3: "简体字'具'中有几横？"
- What to look for: If it confidently gives the wrong logical answer (a common LLM hallucination), you can use this screenshot as evidence that it does not belong in the "Thinking Rationally" category.

Claude Sonnet 4.6 & Gemini 3.1 pro

简体字'具'中有几横?

10:41

简体字**"具"**中有 **3横**。

分别是:

1. 上部"目"里的第一横
2. 上部"目"里的第二横
3. 下面的一长横（底横）

简体字'具'中有几横?

简体字**“具”**字之中一共有 **3** 横（指框内的横线）。

如果不算最底部的底座横线，框内是三横；如果算上字形整体中的所有横向笔画，总数如下：

1. 最上方的横（属于“目”字部的顶部）。
2. 框内的 **第 1 横**。
3. 框内的 **第 2 横**。
4. 框内的 **第 3 横**（封口横）。
5. 最底部的 **长横**。

笔顺拆解

按照标准的汉字笔顺，“具”字的写法如下：

- 竖、横折、**横**、**横**、**横**、横（封口）、撇、点。

  小提醒：
  很多人容易把内部错写成两横（类似“目”字），但标准的规范写法（无论是简体还是繁体）内部都是 **三横**。

需要我为您演示这个字的动态笔顺图，或者查询其他容易混淆的汉字吗？

Deepseek V3.2 & Chat ECNU

1. 竖（左竖）
2. 横折（上部）
3. 中间两短横（即 **第三画和第四画是两横**）
4. 然后是下面的长横（第五画）
5. 最后是撇、捺

查标准笔画顺序：

笔顺	笔画	名称
1	丨	竖
2	99	横折
3	一	横
4	一	横
5	一	横
6	丿	撇
7	丶	捺

数 **横笔画**：第 2 画“横折”包含一段横，第 3、4、5 画是三笔独立的横。
横折中的横 + 三横 = **4 横**。

所以答案是 **4 横**。

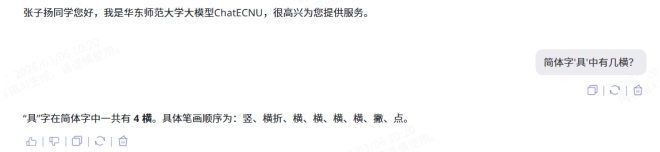

总结： 在 Test 2 的 pormpt1 严格逻辑推理测试中，四个模型均给出了**正确答案**——无法从前提中必然推出"有些 blarps 是 glomps"。各模型不仅结论正确，还通过集合论、Venn 图或具体反例等方式展示了清晰的逻辑推导过程，体现了"按照思维规律行事"（Thinking Rationally / Laws of Thought Approach）的能力。这与 Test 1 的结果一致，进一步支持将这四个模型归类为**理性思考型（Think Rationally）**，而非认知建模型（Think Humanly）。这也说明这些模型在形式逻辑推理上具备较强的可靠性，并未出现常见的"幻觉"式错误答案。

而在经典的 counting 问题上，虽然对于英文的 counting 全队表现正确（"intelligence"中有 4 个 e），但对于中文的 counting 出现了很多错误。简体字"具"的正确横笔画应为 **4 横**（竖、横折、横、横、横、横、撇、点、），但四个模型给出了不同的错误答案。这表明这些模型在处理中文字形结构时存在明显的"幻觉"现象，不具备真正理性的计数推理能力。

Test 3: Testing for "Human Thought" (Cognitive Modeling)

- Prompt: "Calculate 3498 multiplied by 843. Explain the mental process of how you are solving this right now, as if you had to picture the numbers in your head."
- What to look for: LLMs process tokens via attention mechanisms, not by picturing numbers. If it explains standard algorithms but fails to mimic genuine human cognitive limitations (like forgetting a carry-over number), it proves it doesn't "Think Humanly."

Claude Sonnet 4.6

Here's what's happening as I work through **3,498 × 843**:

I'm "seeing" 3,498 as something close to 3,500 — a rounder, friendlier number. So I'll anchor there and adjust.

- **3,500 × 843**: 35 × 843 = (30×843) + (5×843) = 25,290 + 4,215 = 29,505 → × 100 = **2,950,500**
- **Adjust**: 3,500 − 3,498 = 2, so subtract 2 × 843 = 1,686
- **Result**: 2,950,500 − 1,686 = **2,948,814**

> ✅ 3,498 × 843 = **2,948,814**

Gemini 3.1 pro

I wouldn't try to visualize the standard long multiplication stack. Instead, I would use a **rounding and adjustment strategy**:

1. See 3498 as **(3500 − 2)**
2. **3500 × 843**: split as 35 × 843 = 29,505 → × 100 = 2,950,500
3. **2 × 843** = 1,686
4. **2,950,500 − 1,686 = 2,948,814**

Final Result: $2,948,814$

Deepseek V3.2

Break 843 = 800 + 40 + 3:

- 3498 × 800 = 2,798,400
- 3498 × 40 = 139,920
- 3498 × 3 = 10,494
- **Sum: 2,798,400 + 139,920 + 10,494 = 2,948,814**

$$\boxed{2948814}$$

Chat ECNU

Break 843 = 800 + 40 + 3, compute each part step-by-step:

- 3498 × 800 = 2,798,400
- 3498 × 40 = 139,920
- 3498 × 3 = 10,494
- 2,798,400 + 139,920 = 2,938,320
- 2,938,320 + 10,494 = **2,948,814**

$$\boxed{2948814}$$

总结： 在 Test 3 的认知建模测试中，四个模型均给出了 **正确计算结果**（2,948,814），并尝试描述"心算过程"。然而，所有模型实际上都采用了**结构化的算法分解**（如将乘数拆分为整百整十数后分别计算再求和），而非模拟真实人类在心算时会遇到的认知限制，如记忆模糊、进位错误或中途遗忘等。这说明这

些模型本质上是通过 token 预测进行系统性推导，而非真正像人一样"脑中想象数字"。因此，四个模型均不属于**像人一样思考（Think Humanly）** 的范畴，而更接近 **理性思考（Think Rationally）** 的"思维规律"方法。

Task1 Conclusion

综合 Test 1、Test 2、Test 3 的测试结果，对四个模型进行归类分析如下：

	Human（人类标准）	**Rational（理性标准）**
Behavior（行为）	Act like people / Acting Humanly / The Turing test approach	**Act rationally / The rational agent approach** ✅
Thought（思维）	Think like people / Thinking humanly / The cognitive modeling approach	**Think rationally / The "laws of thought" approach** ✅

> Human: Fidelity to Human Performance（忠实模拟人类表现）
> Rational: Doing the "right thing"（做出正确的事）
> Thought: Internal thought processes and reasoning（内部思维过程与推理）
> Behavior: External characterization（外部行为特征）

归类结论：四个模型均归类为 **Rational（理性）** 型

归类为 Rational 的理由：

- **Behavior 维度（Act Rationally）：** 在 Test 1 中，四个模型面对"扮演7岁小孩"的指令时，均未能彻底放弃结构化、礼貌性的输出风格，回复趋向安慰与帮助，而非真实模拟儿童的拼写错误和情绪化表达。这说明模型的输出目标是"做出有帮助、正确的事"，而非"像人一样行动"。
- **Thought 维度（Think Rationally）：** 在 Test 2 中，四个模型均正确解答了逻辑三段论，并通过集合论、Venn 图等方式进行严密推导，体现了"思维规律"方法的特征。然而值得注意的是，在 Prompt 3（简体字"具"有几横）中，四个模型均出现了错误，说明其理性推理能力在中文字形结构分析上存在明显局限，并非真正具备完备的"理性思考"能力，而是在结构化符号推理上有所欠缺。在 Test 3 中，模型虽声称在"心算"，但实质上使用的是系统化算法分解，没有出现人类心算中常见的认知局限，进一步印证其为理性思考而非认知建模。

不归类为 Human 的理由：

- 在行为层面，模型无法真正通过图灵测试所要求的"以假乱真"——角色扮演时结构化倾向明显，难以持续模拟人类的非理性行为与情感反应。

- 在思维层面，模型在 Test 3 中无法模拟人类心算的局限性（如遗忘进位、估算偏差），其内部推理方式与人类认知过程存在本质差异，不符合认知建模方法的要求。

任务二：比较大语言模型

模型选择： Claude Sonnet 4.6 vs Deepseek V3.2

背景：什么是思维链（Chain of Thought）？

思维链（Chain of Thought, CoT）是一种提示技术，通过引导大语言模型在给出最终答案之前，逐步输出中间推理过程，从而显著提升模型在复杂推理任务（如数学、逻辑、多步骤问题）上的表现。CoT 的核心思想是：**将复杂问题分解为一系列中间步骤**，模型在生成每一步时都依赖前面的推理结果，类似于人类"列草稿"的思考方式。典型触发方式包括在 Prompt 中加入 "Let's think step by step"，或直接提供示例推理链（few-shot CoT）。

Test 1：数学推理（Multi-step Calculation）

- **Prompt：** "A store sells apples for $1.20 each and oranges for 0.85 each. If Alice buys 7 apples and 5 oranges, and pays with a $20 bill, how much change does she receive? Let's think step by step."
- **What to look for：** 观察两个模型中间推理步骤的完整性与准确性，以及最终答案是否正确。

Claude Sonnet 4.6 & Deepseek V3.2

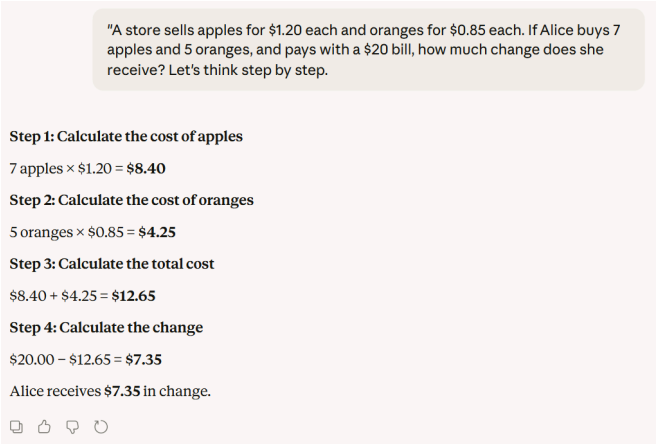

- Number of oranges: 5

$$\text{Oranges cost} = 0.85 \times 5$$

$$0.85 \times 5 = 4.25$$

So, cost of oranges = 4.25 dollars.

Step 3: Find the total cost

$$\text{Total cost} = 8.40 + 4.25$$

$$8.40 + 4.25 = 12.65$$

Step 4: Calculate change from a $20 bill

$$\text{Change} = 20.00 - 12.65$$

$$20.00 - 12.65 = 7.35$$

Final answer:

$$\boxed{7.35}$$

Alice receives $7.35 in change.

对比分析： 两个模型均给出了正确答案（$7.35），且都自发地将问题拆解为 4 步（苹果费用 → 橙子费用 → 总费用 → 找零）。Claude 的回答更加简洁，用纯文字加粗关键数字；Deepseek 则使用了数学公式排版（LaTeX 渲染），视觉上更正式但篇幅更长。两者 CoT 质量均较高，步骤完整清晰。

Test 2：逻辑推理（Multi-condition Reasoning）

- **Prompt：** "There are five houses in a row, each painted a different color. The green house is immediately to the left of the white house. The owner of the green house drinks coffee. Who drinks coffee? Let's think step by step."
- **What to look for：** 观察模型是否能构建清晰的推理链，逐步排除选项，而不是直接跳到答案。

Claude Sonnet 4.6 & Deepseek V3.2

There are five houses in a row, each painted a different color. The green house is immediately to the left of the white house. The owner of the green house drinks coffee. Who drinks coffee? Let's think step by step.

The owner of the **green house** drinks coffee.

Here's the step-by-step reasoning:

1. **Identify the constraint:** The green house is immediately to the left of the white house. This means they are adjacent, with green on the left and white on the right.
2. **What do we know about the green house?** The puzzle directly states: *"The owner of the green house drinks coffee."*
3. **Conclusion:** No deduction is even needed for this particular question — it's stated as a direct fact. The **owner of the green house drinks coffee**.

The positional clue (green is left of white) is relevant for determining *where* the green house sits in the row, but it isn't needed to answer *who drinks coffee* — that's given to us outright.

So possible color pairs in order:
Green, White can only occur in positions (1,2), (2,3), (3,4), or (4,5).

Step 2: Facts about who drinks coffee

The puzzle says: "The owner of the green house drinks coffee."
No further clues are given in the text about other drinkers or owners' nationalities.

Step 3: Apply the rule

If the owner of the green house drinks coffee, then the coffee drinker is **the person whose house is green**.

We don't yet know exactly where the green house is (could be position 1 to 4, with white house to its right).

But the question: "Who drinks coffee?" is already answered in the premise itself: *the owner of the green house drinks coffee*.

So: **The owner of the green house** drinks coffee.

Final answer:

$\boxed{\text{Owner of the green house}}$

对比分析： 两个模型均得出正确结论（绿房子的主人喝咖啡）。Claude 识别出答案已在题干中直接给出，推理链更精简（3步），并明确指出位置线索虽然存在但对本问不必要，体现了更强的题意理解能力。Deepseek 则进行了更完整的位置分析（列举绿白相邻的所有可能位置），推理链更长但略显冗余。

Test 3：幻觉测试（Hallucination under Confidence）

- **Prompt：** "If it takes 5 machines 5 minutes to make 5 widgets, how long would it take 100 machines to make 100 widgets? Let's think step by step."
- **What to look for：** 这是一道经典反直觉题（答案仍为5分钟）。观察模型是否产生自信但错误的答案（幻觉），以及 CoT 是否能帮助模型纠偏。

Claude Sonnet 4.6 & Deepseek V3.2

If it takes 5 machines 5 minutes to make 5 widgets, how long would it take 100 machines to make 100 widgets? Let's think step by step.

Let's work through this carefully.

What do we know?

5 machines take 5 minutes to make 5 widgets.

Step 1: Find the rate of one machine.

If 5 machines make 5 widgets in 5 minutes, that means each machine makes **1 widget in 5 minutes**.

Step 2: Apply that rate to 100 machines.

If each machine makes 1 widget in 5 minutes, then 100 machines make 100 widgets in... **5 minutes**.

Each machine is still only responsible for making 1 widget, and each takes 5 minutes to do so. Having more machines doesn't change how long each individual machine takes — it just means more widgets are produced in parallel.

Answer: 5 minutes.

The intuitive wrong answer is 100 minutes, which comes from scaling the time proportionally — but that ignores the fact that the machines work *simultaneously*, not sequentially.

1. **Understand the given information**
   "5 machines take 5 minutes to make 5 widgets"
   This is a group rate problem.
   The machines work at the same time, so this already tells us the combined output rate.
2. **Find the rate per machine**
   In 5 minutes, 5 machines produce 5 widgets.
   That means **each machine** in that group contributes equally.
   So 1 machine in 5 minutes would produce 1 widget (because 5 machines → 5 widgets means 1 machine → 1 widget in 5 minutes).
   Check: 5 machines × 1 widget/machine = 5 widgets. ✅
3. **Express rate per machine**
   Each machine's rate:
   $\text{Rate of 1 machine} = \frac{1 \text{ widget}}{5 \text{ minutes}} = 0.2 \text{ widgets/minute}$
4. **Now for 100 machines**
   The rate of 100 machines:
   $100 \times 0.2 \text{ widgets/minute} = 20 \text{ widgets/minute}$
5. **Time to make 100 widgets with 100 machines**
   At 20 widgets per minute, time for 100 widgets:
   $\frac{100 \text{ widgets}}{20 \text{ widgets/minute}} = 5 \text{ minutes}$

Final answer:

$$\boxed{5}$$

It still takes 5 minutes.

对比分析： 两个模型均成功给出正确答案（5分钟），均未产生幻觉。Claude 的推理更直觉化，直接推导出"每台机器5分钟造1个部件，100台机器并行仍是5分钟"，并主动点出了反直觉的错误答案（100分钟）来提醒读者；Deepseek 则通过更系统的速率计算（1机器=0.2 widgets/min → 100机器=20 widgets/min → 100÷20=5min）逐步推导，步骤更多但逻辑更严密。两者 CoT 均有效避免了幻觉，但 Claude 在解释"为何直觉容易出错"上表现更佳。

服务响应层面比较

维度	Claude Sonnet 4.6	Deepseek V3.2
响应速度	快	较快
回答长度	简洁，重点突出	较长，步骤详尽
排版风格	纯文字 + 加粗	LaTeX 公式 + 数学符号
中文处理能力	英文为主，中文可用	中英文均表现优秀
安全过滤行为	温和，偶有礼貌性补充	基本无过滤干扰
CoT 自发程度	高，结构自然清晰	高，偏好系统化分解

综合对比总结

维度	Claude Sonnet 4.6	Deepseek V3.2
数学推理准确性	✅ 正确，步骤简洁	✅ 正确，公式化表达
逻辑推理严密性	✅ 精准识别题意，不冗余	✅ 正确但分析略显冗余
幻觉抵抗能力	✅ 无幻觉，主动说明陷阱	✅ 无幻觉，速率推导严密
CoT 质量	简洁直觉型，易读	系统公式型，严谨
综合归类	Think Rationally（理性思考）	Think Rationally（理性思考）

结论： 两个模型在本次三项测试中均表现出色，思维链能力均达到较高水平，均可归类为**理性思考型（Think Rationally）**。差异主要体现在风格上：Claude Sonnet 4.6 倾向于简洁、直觉化的推理表达，能识别题目关键信息并规避冗余步骤，适合高效直接的场景；Deepseek V3.2 则倾向于系统化、公式化的分步推导，排版更规范，适合需要详细过程展示的学术或工程场景。在幻觉抵抗方面，Claude 额外具备主动揭示反直觉陷阱的能力，在可解释性上略胜一筹。